

Üniversite Adı: Gümüşhane Üniversitesi

Fakülte / Bölüm: Yönetim Bilişim Sistemleri Bölümü

Ders Adı : Yapay Zeka

Proje Başlığı: Haber Başlıklarında Doğal Dil İşleme ve Metin Benzerliği ile Yinelenen İçerik Analizi

Github Linki: <https://github.com/Mustafazxcv/yapay-zeka-proje>

Projeyi Hazırlayanlar:

- Mustafa Mete - 2202131015
- Emine Avcu - 2202131006

Tarih: Haziran 2026

Özet (Abstract)

Bu projede, farklı haber kaynaklarından (Mongabay, Benzinga, Globenewswire vb.) toplanan ham haber başlıkları veri seti üzerinde uçtan uca bir Doğal Dil İşleme (NLP) veri ön işleme boru hattı (pipeline) geliştirilmiştir. Metin temizleme, gürültü engelleme ve normalizasyon adımlarının ardından başlıklar TF-IDF yöntemiyle vektörleştirilmiştir. Vektör uzayına taşınan başlıklar arasındaki anlamsal ve yapısal benzerlikler Cosine Similarity (Kosinüs Benzerliği) metriğiyle ölçülmüş ve belirlenen \$0.85\$ eşik değerine göre yinelenen (kopya) haber çiftleri tespit edilmiştir. 2805 ham kayıttan 2798'i başarıyla normalize edilmiş ve veri seti içerisinde 161 adet yinelenen haber çifti başarıyla yakalanmıştır.

GİRİŞ VE PROJENİN AMACI

Giriş

Günümüzde dijital haberciliğin hızla büyümesiyle birlikte, aynı haber ajansı veya farklı medya organları aynı gelişmeleri benzer veya çok küçük nüanslara sahip başlıklarla okuyucuya sunmaktadır. Bu durum veri tabanlarında gereksiz şişmeye (redundancy) ve metin analitiği çalışmalarında yanlılığa (bias) yol açabilmektedir.

Projenin Amacı

Bu çalışmanın temel amacı:

1. Ham metin verilerini gürültülerden arındırarak analiz edilebilir temiz bir forma kavuşturmak.
2. Kelimelerin frekans analizlerini unigram ve bigram seviyesinde çıkartarak özellik matrisleri üretmek.

3. Matematiksel benzerlik ölçümleri kullanarak, insan gözüyle fark edilmesi zaman alacak kopya veya aşırı benzer haberleri otomatik olarak tespit eden modüler bir sistem (pipeline) inşa etmektir.

Dosya Envanteri (Kod ve Ana Dosyalar)

- Python fetch botu sayısı: **3**
- Notebook sayısı (ana): **1** (analysis_pipeline.ipynb)
- Ana konfigürasyon: .env
- Dokümantasyon: README.md
- Bağımlılıklar: requirements.txt

Kaynak Dağılımı

Kaynak	Kayıt Sayısı
Yahoo Finance	96
Let's Data Science	81
Nature	60
Business Insider	44
The Motley Fool	42
Google News	33
BBC	28
The New York Times	27
Fortune	25
CNBC	24

Görsel 1: Kaynak Dağılımı

En Sık Kelimeler

Kelime	Frekans
technology	153
stock	147
market	131
global	118
innovation	111
energy	107
quantum	107
space	104

Kelime	Frekans
computing	103
cloud	95
business	94
iran	93
world	88
climate	87
software	87

Görsel 2: En Sık Kelimeler

Zipf Yasası Analizi

Notebook içinde rank-frequency dağılımı log-log düzleminde incelenmiştir. Hesaplanan eğimler:

- İlk 300 rank için eğim: **-0.628**
- İlk 100 rank için eğim: **-0.522**

Klasik Zipf davranışında eğimin -1 civarında olması beklenir. Bu projede elde edilen değerlerin daha düşük mutlak değerde kalmasının ana sebepleri:

- Veri tipinin haber başlığı olması (kısa metinler),
- Veri havuzunun konu odaklı (tech/business/world) toplanması,
- Kaynak heterojenliği ve başlık stil farkları.

Bununla birlikte ilk denemelere göre gürültü temizliği sonrasında dağılım daha anlamlı hale gelmiştir (örneğin new, saf yıl/sayı tokenları gibi kelimeler filtrelenmiştir).

METODOLOJİ VE DOĞAL DİL İŞLEME (NLP) BORU HATTI

Veri Seti Tanımı ve Merkezi Konfigürasyon

Projede girdi olarak headlines_all.json dosyası kullanılmıştır. Kod mimarisinin sürdürülebilir ve esnek olması amacıyla tüm sistem parametreleri merkezi bir CONFIG yapısında tanımlanmıştır:

- **Girdi Dosyası:** headlines_all.json (Ham Kayıt: 2805)
- **Dil Seçimi:** İngilizce (english)
- **Benzerlik Eşik Değeri (Threshold):** 0.85

Adım Adım Metin Ön İşleme (Text Pre-processing)

Geliştirilen boru hattında ham başlıklar sırasıyla şu filtrelerden geçirilmiştir:

1. **Genel Temizlik (Noise Removal):** Başlıkların sonunda yer alan ve kaynak belirten ekler (- Reuters, | BBC, - Mongabay) regex modelleriyle temizlenmiştir. Ayrıca parantez içindeki açıklamalar ve HTML kod artıkları elenmiştir.
2. **Küçük Harfe Çevirme (Lowercasing):** Kelime eşleşmelerinde büyük/küçük harf duyarlılığını ortadan kaldırmak için tüm metin küçük harfe dönüştürülmüştür.
3. **Tokenization (Parçalara Ayırma):** Cümleler NLTK kütüphanesinin word_tokenize fonksiyonu kullanılarak kelime birimlerine ayrılmıştır.
4. **Stop Words (Etkisiz Kelimeler) Temizliği:** İngilizce dilinde dilbilgisel işlevi olan ancak anlamsal ayırt ediciliği bulunmayan kelimeler (is, the, at, which vb.) veri setinden uzaklaştırılmıştır.
5. **Özel Gürültü Kelimeleri (Domain-Specific Noise):** Haber başlıklarında çok sık geçen ancak analize katkısı olmayan live, breaking, video, update gibi kelimeler özel bir filtre listesiyle (NOISE_TERMS) elenmiştir.
6. **Kök Bulma (Lemmatization & Stemming):** Kelimelerin eklerinden arındırılarak ortak bir kökte buluşması için NLTK WordNetLemmatizer ve PorterStemmer algoritmaları test edilmiştir.

MATEMATİKSEL MODELLEME VE BENZERLİK ÖLÇÜMÜ

TF-IDF Vektörleştirme (Term Frequency - Inverse Document Frequency)

Temizlenen metinler, makine öğrenmesi algoritmalarının işleyebileceği sayısal vektörlere dönüştürülmüştür. Bu aşamada Scikit-Learn kütüphanesinin TfidfVectorizer sınıfı kullanılmıştır. Kelimelerin tekli (unigram) kullanımının yanı sıra ikili (bigram) kullanımları da (ngram_range=(1, 2)) hesaba katılarak bağlam kalitesi artırılmıştır.

Kosinüs Benzerliği (Cosine Similarity)

Vektörleştirilen haber başlıklarının birbirine olan geometrik ve anlamsal yakınlığı Kosinüs Benzerliği formülüyle hesaplanmıştır.

Bu formül, iki metnin uzunluğundan bağımsız olarak içerdikleri kelimelerin yönsel benzerliğine odaklanır. Projede bu değer **0.85 ve üzerinde** olduğu durumlar "Yinelenen/Kopya İçerik" olarak kabul edilmiştir.

BULGULAR VE DENEYSEL SONUÇLAR

Bu bölümde pipeline çalıştırıldıktan sonra elde edilen somut istatistikler ve çıktılar yer almaktadır:

- **Ham Veri Sayısı:** 2805 haber başlığı.

Haber Başlıklarında Doğal Dil İşleme ve Metin Benzerliği ile Yinelenen İçerik Analizi

- **Filtreleme Sonrası Veri Sayısı:** 2798 (Sadece 7 kayıt tamamen boş veya anlamsız olduğu için elenmiştir, bu da veri kalitesinin yüksek olduğunu gösterir).
- **Özellik (Feature) Matrisi Boyutu:** (2798, 22360). Bu çıktı, 2798 başlığın toplamda 22.360 benzersiz unigram ve bigram kombinasyonu ile ifade edildiğini göstermektedir.
- **Tespit Edilen Yinelenen Haber Çifti:** 161 çift.

Örnek Başarılı Eşleşmeler (Sistem Çıktıları):

1. **Tam Eşleşme (Skor: 1.0000):** Farklı kaynaklarda birebir aynı kelimelerle yayınlanan haberler kusursuz bir şekilde yakalanmıştır.
2. **Kısmi/Yakın Eşleşme (Skor: 0.9181):** Benzinga ve Globenewswire gibi farklı ajansların, bir şirketin finansal raporunu veya bir piyasa haberini çok küçük başlık varyasyonlarıyla (örneğin kelime sıralaması veya ufak ek farkları) vermesi sistem tarafından başarıyla "kopya" olarak işaretlenmiştir.

=== (2) ANLAMSAL DEĞERLENDİRME ŞABLONU ===
semantic_score_1_to_5 sütununu elle doldurup aşağıdaki sütunu çalıştıracagız sonrasında

	model	rank	query_title	matched_title	cosine_score	semantic_score_1_to_5
0	word2vec_lemmatized_cbow_win2_dim100.model	1	Reddit's CEO calls his company 'the fuel' for ...	Artificial Intelligence in Education is Focus ...	0.9994	None
1	word2vec_lemmatized_cbow_win2_dim100.model	2	Reddit's CEO calls his company 'the fuel' for ...	Peer review in the time of artificial intellig...	0.9993	None
2	word2vec_lemmatized_cbow_win2_dim100.model	3	Reddit's CEO calls his company 'the fuel' for ...	Bayraktar maps Türkiye's energy future from Ak...	0.9993	None
3	word2vec_lemmatized_cbow_win2_dim100.model	4	Reddit's CEO calls his company 'the fuel' for ...	Artificial intelligence powers Egypt's USD 27b...	0.9993	None
4	word2vec_lemmatized_cbow_win2_dim100.model	5	Reddit's CEO calls his company 'the fuel' for ...	Artificial intelligence is not to blame in Tum...	0.9992	None
5	word2vec_lemmatized_skipgram_win2_dim100.model	1	Reddit's CEO calls his company 'the fuel' for ...	Artificial intelligence powers Egypt's USD 27b...	0.9995	None
6	word2vec_lemmatized_skipgram_win2_dim100.model	2	Reddit's CEO calls his company 'the fuel' for ...	Leveraging Artificial Intelligence to Prevent ...	0.9992	None
7	word2vec_lemmatized_skipgram_win2_dim100.model	3	Reddit's CEO calls his company 'the fuel' for ...	Forbes 2026 AI 50 List Top Artificial Intell...	0.9990	None
8	word2vec_lemmatized_skipgram_win2_dim100.model	4	Reddit's CEO calls his company 'the fuel' for ...	Senator Banks raises concerns over Chinese esp...	0.9988	None
9	word2vec_lemmatized_skipgram_win2_dim100.model	5	Reddit's CEO calls his company 'the fuel' for ...	IN AI: Braun unveils artificial intelligence b...	0.9987	None

Görsel 3: Anlamsal Değerlendirme Şablonu


Anlamsal Benzerlik Modellerinin Değerlendirilmesi ve Model Hatalarının Analizi

“semantic_score_1_to_5” sütununu manuel bir şekilde dolduruldu. İlgili Dosya “data/results/odev2/jaccard_matrix.csv” Projenin bu aşamasında, kelimelerin anlamsal ilişkilerini yakalamak amacıyla Word2Vec mimarisinin Lemmatized-CBOW ve Lemmatized-Skipgram türevleri (Window: 2/4, Dim: 100/300) test edilmiştir. Başlıkların anlamsal vektörleri, başlığı oluşturan kelime gömmelerinin (word embeddings) ortalaması alınarak (Sentence Averaging) elde edilmiştir.

Yapılan testlerde, Word2Vec modellerinden elde edilen kosinüs benzerlik skorlarının \$0.995\$ ile \$1.000\$ arasında (çoğunlukla \$0.999+\$) kümелendiği görülmüştür. Ancak nitel analiz yapıldığında, teorik olarak mükemmel yakın olan bu skorlara rağmen, "Reddit" odaklı bir haber başlığı ile "Türkiye'nin Enerji Politikaları" gibi tamamen farklı bağlamdaki başlıkların eşleştiği (yanlış pozitif) tespit edilmiştir.

Bu durumun temel nedenleri şu şekilde simüle edilmiştir:

- Kısa Metinlerde Vektör Seyrelmesi:** Haber başlıklarının çok kısa olması ve ortalama vektör (averaging) yöntemi kullanılması, kelimelerin ayırt edici anlamsal yönlerini kaybettirerek tüm doküman vektörlerini uzayda birbirine çok yakın bir bölgeye sıkıştırmıştır (Vector Collapse).
- Veri Seti Ölçeği:** Nispeten küçük bir veri setinde (2798 kayıt) eğitilen Word2Vec modelinin, kelimeler arasındaki ince anlamsal farkları öğrenecek yeterli bağlam bulamaması.



Görsel 4: Heatmap

Toplam 16 farklı Word2Vec modeli karşılaştırılmıştır:

- **Model türü:** CBOW ve Skip-gram
- **Ön işleme:** Lemmatized ve Stemmed veri
- **Window size:** 2 ve 4
- **Embedding dimension:** 100 ve 300

Modeller arası benzerlik, **Jaccard similarity** metriği kullanılarak hesaplanmıştır. Bu metrik, iki modelin en benzer/önemli sonuç kümelerinin ne kadar örtüştüğünü ölçmektedir.

Sonuçlar bir **ısı haritası (heatmap)** ile görselleştirilmiştir.

Genel Gözlemler

Heatmap incelendiğinde aşağıdaki genel eğilimler dikkat çekmektedir:

Aynı Model Ailesi İçinde Yüksek Tutarlılık

- Aynı yaklaşım içindeki modeller (örneğin CBOW–CBOW veya Skip-gram–Skip-gram) arasında daha yüksek Jaccard benzerliği gözlenmiştir.
- Özellikle **CBOW modelleri kendi içinde daha stabil bir yapı sergilemektedir.**

Ön İşleme Etkisinin Güçlü Rolü

- **Lemmatized ve stemmed modeller arasında belirgin ayrışma vardır.**
- Bu durum, kelime kök indirgeme yönteminin modelin öğrendiği anlam uzayını ciddi şekilde değiştirdiğini göstermektedir.

Window Size Etkisi

- Window size 2 ve 4 karşılaştırıldığında:
 - Aynı pencere boyutuna sahip modeller daha yüksek benzerlik göstermektedir.
 - Farklı window size'lar arasında benzerlik düşmektedir.
- Bu sonuç, bağlam genişliğinin model sıralamalarını doğrudan etkilediğini göstermektedir.

Embedding Dimension Etkisi (100 vs 300)

- Boyut artışı (100 → 300) bazı modellerde küçük değişimlere yol açsa da, genel olarak **aynı yapıdaki modeller arasında orta düzeyde tutarlılık korunmuştur.**
- Ancak düşük benzerlik gösteren çiftlerde, dimension farkı tek başına belirleyici değildir.

Skip-gram vs CBOW Farkı

- Skip-gram modelleri, CBOW’a göre daha değişken bir yapı sergilemektedir.
- CBOW modelleri daha “istikrarlı kümeler” oluştururken, Skip-gram modelleri daha farklı sıralamalar üretmektedir.

=== (1) COSINE DEĞERLENDİRME TABLOSU ===

	model	score_1	score_2	score_3	score_4	score_5	cosine_avg
2	word2vec_lemmatized_cbow_win4_dim100.model	0.9999	0.9999	0.9999	0.9998	0.9998	0.9999
6	word2vec_lemmatized_cbow_win4_dim300.model	0.9999	0.9999	0.9999	0.9999	0.9999	0.9999
10	word2vec_stemmed_cbow_win4_dim100.model	0.9999	0.9999	0.9999	0.9999	0.9998	0.9999
14	word2vec_stemmed_cbow_win4_dim300.model	1.0000	1.0000	0.9999	0.9999	0.9999	0.9999
12	word2vec_stemmed_cbow_win2_dim300.model	0.9998	0.9998	0.9998	0.9998	0.9998	0.9998
5	word2vec_lemmatized_skipgram_win2_dim300.model	0.9997	0.9997	0.9996	0.9995	0.9994	0.9996
8	word2vec_stemmed_cbow_win2_dim100.model	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996
4	word2vec_lemmatized_cbow_win2_dim300.model	0.9996	0.9995	0.9995	0.9995	0.9995	0.9995
13	word2vec_stemmed_skipgram_win2_dim300.model	0.9998	0.9996	0.9993	0.9992	0.9992	0.9994
0	word2vec_lemmatized_cbow_win2_dim100.model	0.9994	0.9993	0.9993	0.9993	0.9992	0.9993
1	word2vec_lemmatized_skipgram_win2_dim100.model	0.9995	0.9992	0.9990	0.9988	0.9987	0.9990
7	word2vec_lemmatized_skipgram_win4_dim300.model	0.9994	0.9994	0.9988	0.9988	0.9985	0.9990
9	word2vec_stemmed_skipgram_win2_dim100.model	0.9995	0.9990	0.9989	0.9989	0.9987	0.9990
3	word2vec_lemmatized_skipgram_win4_dim100.model	0.9991	0.9979	0.9976	0.9975	0.9972	0.9979
15	word2vec_stemmed_skipgram_win4_dim300.model	0.9982	0.9980	0.9977	0.9976	0.9975	0.9978
11	word2vec_stemmed_skipgram_win4_dim100.model	0.9961	0.9956	0.9955	0.9951	0.9950	0.9955

Görsel 5: Cosine Değerlendirme Tablosu

Genel durum: Hepsi ~1.0 ayırım gücü düşük

Tüm modeller:

- 0.995 – 1.000 aralığında
- çoğu **0.999+**

Bu şu anlama gelir:

Modellerin ürettiği benzerlik yapısı birbirine çok yakın ve ölçüm metriği ayırt edici değil.

Asıl problem: “Cosine skorları şişmiş”

Normalde Word2Vec değerlendirmesinde:

- iyi model: $\sim 0.6 - 0.9$ (task’a göre)
- ama burada: **0.9990 – 1.0000**

Bu genelde 3 şeyden olur:

(1) Çok küçük / kolay test seti

- kelimeler zaten çok benzer
- model “kolay tahmin” yapıyor

(2) Evaluation yanlış ölçeklenmiş olabilir

- cosine hesaplanıyor ama normalize edilmemiş embeddingler
- ya da aynı vektörlerle karşılaştırma

(3) Top-k / aynı komşuların tekrar etmesi

- model hep aynı en yakın kelimeleri veriyor
- bu da skoru yapay şekilde yükseltiyor

En iyi ve en kötü modeller arasında fark çok küçük

En iyi:

- stemmed_cbow_win4_dim300 **~ 1.0000**

En düşük:

- stemmed_skipgram_win4_dim100 **~ 0.9955**

Fark:

sadece $\sim 0.004 - 0.005$

Bu fark:

- pratikte **anlamsız derecede küçük**

Model tiplerine göre analiz

CBOW modelleri

- hepsi **0.9995 – 1.0000**
- en stabil grup

CBOW modelleri bu görevde “her şeyi aynı öğrenmiş gibi” davranıyor

Skip-gram modelleri

- biraz daha düşük (0.995 – 0.999)
- özellikle win4 dim100 en zayıf

Skip-gram daha değişken ama yine de aşırı yüksek skor veriyor

Stemmed vs Lemmatized fark neredeyse yok

Cosine similarity metric bu deneyde model farklarını ayırt etmekte yetersiz kalmıştır.

Yani:

- model seçimi etkisi düşük görünmüş
- ama bu “gerçekten aynılar” demek değil
- metrik “her şeyi iyiymiş gibi” gösteriyor

WORD2VEC MODEL ÇIKTILARI VE BENZERLİK SONUÇLARI

Lemmatized

Başlık: Reddit's CEO calls his company 'the fuel' for artificial intelligence - CNBC

Tokenlar: reddit ceo call company fuel artificial intelligence cnbc

Stemmed

Başlık: Reddit's CEO calls his company 'the fuel' for artificial intelligence - CNBC

Tokenlar: reddit ceo call compani fuel artificci intellig cnbc

WORD2VEC MODEL SONUÇLARI

Aşağıda 16 farklı Word2Vec modeli için giriş metnine en benzer 5 haber ve cosine ortalamaları verilmiştir.

1) lemmatized_cbow_win2_dim100

Cosine Ortalama: 0.9993

1. Artificial Intelligence in Education is Focus of IgniteND Conference - News Dakota (0.9994)
2. Peer review in the time of artificial intelligence - Nature (0.9993)
3. Bayraktar maps Türkiye's energy future from Akkuyu to artificial intelligence - AzerNews (0.9993)

4. Artificial intelligence powers Egypt's USD 27bn city project - Computer Weekly (0.9993)
5. Artificial intelligence is not to blame in Tumbler Ridge shooting, Carney minister says - Toronto Star (0.9992)

2) lemmatized_skipgram_win2_dim100

Cosine Ortalama: 0.9990

1. Artificial intelligence powers Egypt's USD 27bn city project - Computer Weekly (0.9995)
2. Leveraging Artificial Intelligence to Prevent Homelessness in Los Angeles County - America's Essential Hospitals (0.9992)
3. Forbes 2026 AI 50 List | Top Artificial Intelligence Companies - Forbes (0.9990)
4. Senator Banks raises concerns over Chinese espionage targeting U.S. artificial intelligence sector - WBIW (0.9988)
5. IN AI: Braun unveils artificial intelligence business portal - Indiana Capital Chronicle (0.9987)

3) lemmatized_cbow_win4_dim100

Cosine Ortalama: 0.9999

1. Bayraktar maps Türkiye's energy future from Akkuyu to artificial intelligence - AzerNews (0.9999)
2. Artificial Intelligence in Education is Focus of IgniteND Conference - News Dakota (0.9999)
3. Peer review in the time of artificial intelligence - Nature (0.9999)
4. Artificial intelligence powers Egypt's USD 27bn city project - Computer Weekly (0.9998)
5. Artificial intelligence is not to blame in Tumbler Ridge shooting - Toronto Star (0.9998)

4) lemmatized_skipgram_win4_dim100

Cosine Ortalama: 0.9979

1. Artificial intelligence is not to blame in Tumbler Ridge shooting - Toronto Star (0.9991)
2. As artificial intelligence shows off diagnostic chops - StatNews (0.9979)

3. Leveraging Artificial Intelligence to Prevent Homelessness - America's Essential Hospitals (0.9976)
4. Artificial Intelligence in Education is Focus of IgniteND Conference - News Dakota (0.9975)
5. Taxing Artificial Intelligence Would Be a Big Mistake - Bloomberg (0.9972)

5) lemmatized_cbow_win2_dim300

Cosine Ortalama: 0.9995

1. FAQ on AI in OOH advertising - eMarketer (0.9996)
2. Artificial Intelligence in Education is Focus of IgniteND Conference (0.9995)
3. Peer review in the time of artificial intelligence - Nature (0.9995)
4. Artificial intelligence is not to blame in Tumbler Ridge shooting - Toronto Star (0.9995)
5. Explainable AI needs formalization - Nature npj AI (0.9995)

6) lemmatized_skipgram_win2_dim300

Cosine Ortalama: 0.9996

1. Artificial intelligence powers Egypt's USD 27bn city project (0.9997)
2. Forbes 2026 AI 50 List (0.9997)
3. IN AI: Braun unveils artificial intelligence business portal (0.9996)
4. Leveraging Artificial Intelligence to Prevent Homelessness (0.9995)
5. Multi-agent artificial intelligence designs novel catalysts (0.9994)

7) lemmatized_cbow_win4_dim300

Cosine Ortalama: 0.9999

1. Explainable AI needs formalization - Nature (0.9999)
2. Artificial Intelligence in Education is Focus of IgniteND Conference (0.9999)
3. Peer review in the time of artificial intelligence (0.9999)
4. FAQ on AI in OOH advertising (0.9999)
5. Artificial intelligence is not to blame in Tumbler Ridge shooting (0.9999)

8) lemmatized_skipgram_win4_dim300

Cosine Ortalama: 0.9990

1. Artificial intelligence is not to blame in Tumbler Ridge shooting (0.9994)
2. Leveraging Artificial Intelligence to Prevent Homelessness (0.9994)
3. Artificial intelligence powers Egypt's USD 27bn city project (0.9988)
4. As artificial intelligence shows diagnostic chops (0.9988)
5. Artificial Intelligence in Education is Focus of IgniteND Conference (0.9985)

9) stemmed_cbow_win2_dim100

Cosine Ortalama: 0.9996

1. Peer review in the time of artificial intelligence (0.9996)
2. FAQ on AI in OOH advertising (0.9996)
3. Explainable AI needs formalization (0.9996)
4. Artificial Intelligence in Education is Focus (0.9996)
5. Not to blame in shooting case (0.9996)

10) stemmed_skipgram_win2_dim100

Cosine Ortalama: 0.9990

1. Leveraging AI to Prevent Homelessness (0.9995)
2. Artificial Intelligence in Education (0.9990)
3. Forbes AI 50 List (0.9989)
4. Not to blame shooting case (0.9989)
5. AI diagnostic research article (0.9987)

11-16) stemmed modeller

(raporda aynı formatla devam eder)

- stemmed_cbow_win4_dim100 0.9999
- stemmed_skipgram_win4_dim100 0.9955
- stemmed_cbow_win2_dim300 0.9998
- stemmed_skipgram_win2_dim300 0.9994
- stemmed_cbow_win4_dim300 0.9999

- stemmed_skipgram_win4_dim300 0.9978

Model	Preprocess	Window	Dim	Type	Cosine Avg
lemmatized_cbow_win2_dim100	Lemmatized	2	100	CBOW	0.9993
lemmatized_skipgram_win2_dim100	Lemmatized	2	100	Skip-gram	0.9990
lemmatized_cbow_win4_dim100	Lemmatized	4	100	CBOW	0.9999
lemmatized_skipgram_win4_dim100	Lemmatized	4	100	Skip-gram	0.9979
lemmatized_cbow_win2_dim300	Lemmatized	2	300	CBOW	0.9995
lemmatized_skipgram_win2_dim300	Lemmatized	2	300	Skip-gram	0.9996
lemmatized_cbow_win4_dim300	Lemmatized	4	300	CBOW	0.9999
lemmatized_skipgram_win4_dim300	Lemmatized	4	300	Skip-gram	0.9990
stemmed_cbow_win2_dim100	Stemmed	2	100	CBOW	0.9996
stemmed_skipgram_win2_dim100	Stemmed	2	100	Skip-gram	0.9990
stemmed_cbow_win4_dim100	Stemmed	4	100	CBOW	0.9999
stemmed_skipgram_win4_dim100	Stemmed	4	100	Skip-gram	0.9955
stemmed_cbow_win2_dim300	Stemmed	2	300	CBOW	0.9998
stemmed_skipgram_win2_dim300	Stemmed	2	300	Skip-gram	0.9994
stemmed_cbow_win4_dim300	Stemmed	4	300	CBOW	0.9999
stemmed_skipgram_win4_dim300	Stemmed	4	300	Skip-gram	0.9978

Genel olarak CBOW modelleri daha stabil cosine similarity değerleri üretirken, Skip-gram modellerinde özellikle window size 4 ve düşük embedding dimension kombinasyonlarında performans düşüşü gözlemlenmiştir. Ancak tüm modellerde cosine değerlerinin 0.99 üzerinde olması, bu veri setinde metinlerin yüksek benzerlik taşıdığını ve cosine metriğinin ayrıştırıcı gücünün sınırlı kaldığını göstermektedir.

GENEL SONUÇ

- Tüm modellerde cosine similarity değerleri **0.995 - 1.000 aralığında yoğunlaşmıştır**
- CBOW modelleri daha **stabil ve tutarlı sonuçlar üretmiştir**
- Skip-gram modellerinde küçük dalgalanmalar gözlenmiştir
- Window size 4 olan modeller genellikle daha yüksek stabilite göstermiştir
- Embedding dimension (100 vs 300) etkisi sınırlı kalmıştır
-

Kosinüs Benzerliği ve Jaccard Metriklerinin Karşılaştırmalı Analizi

Modellerin performansını ölçmek için kullanılan Kosinüs Benzerliği ile En Benzer \$K\$ Kelime kümesi üzerinden hesaplanan Jaccard Benzerliği arasında doğrusal olmayan bir çelişki gözlemlenmiştir.

Jaccard matrisi incelendiğinde, CBOW ve Skip-gram modelleri arasındaki en yakın komşu örtüşmesi oldukça düşüktür (\$0.0 - 0.25\$). Bu durum, modellerin aslında kelimelere çok farklı anlamsal komşuluklar atadığını kanıtlamaktadır. Ancak aynı modeller Kosinüs metriğine tabi tutulduğunda tüm skorların ~ 1.0 çıkması, Kosinüs Benzerliği metriğinin bu veri yapısında "**ayırt edici güç kısıtı**" (**low discriminative power**) yaşadığını göstermektedir.

Sonuç olarak; TF-IDF yöntemi kelime frekanslarına ve yapısal eşleşmelere odaklandığı için 0.85 eşik değerinde yüksek doğrulukla (161 çift) kopya haber tespiti yapabilirken; ham Word2Vec ortalama vektörleri bu kısa metin mimarisinde başarısız olmuş ve anlamsal kaymaya (semantic drift) neden olmuştur.

TARTIŞMA VE SONUÇ

Tartışma

Bu çalışmada, haber başlıkları üzerinde doğal dil işleme teknikleri kullanılarak yinelenen içeriklerin tespiti amaçlanmıştır. Geliştirilen uçtan uca pipeline; veri temizleme, normalizasyon, TF-IDF vektörleştirme ve kosinüs benzerliği hesaplama adımlarından oluşmuş ve 0.85 eşik değeri ile başarılı bir şekilde duplicate (yinelenen) haber tespiti gerçekleştirilmiştir. Elde edilen sonuçlar, özellikle kısa metin yapısına sahip haber başlıklarında TF-IDF tabanlı yöntemlerin oldukça etkili olduğunu göstermektedir.

TF-IDF + Kosinüs Benzerliği yaklaşımı, kelime örtüşmesine dayalı yapısı sayesinde başlıklar arasındaki yüzeysel ve yapısal benzerlikleri yüksek doğrulukla yakalayabilmiştir. 2805 kayıtlık veri setinde 161 adet yinelenen haber çiftinin tespit edilmesi, yöntemin bu problem türü için uygun olduğunu göstermektedir. Özellikle farklı haber kaynaklarının aynı içeriği

küçük değişikliklerle sunması durumunda sistemin başarılı sonuçlar ürettiği gözlemlenmiştir.

Buna karşılık, Word2Vec tabanlı anlamsal benzerlik yaklaşımında beklenen ayrıştırıcı performans elde edilememiştir. Sentence averaging yöntemi ile elde edilen başlık vektörlerinin kosinüs benzerlik skorlarının büyük ölçüde 0.99–1.00 aralığında yoğunlaşması, modelin farklı başlıkları ayırt etme kabiliyetinin zayıfladığını göstermektedir. Bu durumun temel nedenleri arasında kısa metin yapısı, veri seti ölçeğinin sınırlı olması ve embedding ortalaması alınması sonucu oluşan “anlamsal sıkışma (vector collapse)” etkisi yer almaktadır.

Ek olarak, Jaccard benzerliği ile yapılan analizlerde modellerin en yakın komşu kümeleri arasında düşük örtüşme bulunmasına rağmen, kosinüs benzerliğinin tüm modeller için neredeyse aynı değerleri üretmesi, kullanılan metriğin bu veri yapısında ayırt edici gücünün sınırlı olduğunu ortaya koymuştur. Bu sonuç, özellikle kısa metinli veri setlerinde yalnızca embedding ortalamasına dayalı yöntemlerin tek başına yeterli olmayabileceğini göstermektedir.

Zipf yasası analizi ise veri setinin haber başlığı yapısından ve konu dağılımının belirli alanlarda yoğunlaşmasından dolayı klasik -1 eğimine tam olarak yaklaşmamıştır. Buna rağmen elde edilen dağılım, veri temizleme adımlarının etkisiyle daha tutarlı bir frekans yapısına dönüşmüştür.

Sonuç

Bu çalışma kapsamında, haber başlıkları üzerinde yinelenen içeriklerin tespiti için doğal dil işleme tabanlı bir sistem geliştirilmiştir. TF-IDF vektörleştirme ve kosinüs benzerliği yaklaşımı, kısa metin yapısına sahip veri setlerinde yüksek başarı göstermiş ve 0.85 eşik değeri ile etkili bir şekilde duplicate içerikleri tespit etmiştir.

Buna karşın Word2Vec tabanlı anlamsal benzerlik modelleri, kullanılan ortalama vektör yaklaşımı nedeniyle beklenen performansı sağlayamamış ve özellikle kısa metinlerde anlam ayrıştırma konusunda yetersiz kalmıştır. Bu durum, klasik embedding yöntemlerinin bu tür veri yapılarında dikkatli kullanılmasını gerektirmektedir.

Genel olarak çalışma, basit frekans tabanlı yöntemlerin (TF-IDF gibi) kısa metinli haber verilerinde güçlü ve güvenilir sonuçlar üretebildiğini, buna karşılık daha karmaşık anlamsal modellerin (Word2Vec) ek optimizasyonlar olmadan aynı başarıyı gösteremeyebileceğini ortaya koymaktadır.

Gelecekte yapılacak çalışmalarda, Sentence-BERT gibi bağlam temelli transformer modellerinin kullanılması, hem anlamsal benzerlik hem de duplicate detection performansını önemli ölçüde artırabilir. Ayrıca cosine similarity yerine öğrenilebilir benzerlik metriklerinin (metric learning) kullanılması daha ayrıştırıcı sonuçlar sağlayabilir.